



Université de
Sherbrooke

IFT 599 / IFT 799 - Science de données

TP1 : Compréhension et visualisation des données

Automne 2026

Enseignant

	Courriel	Local	Téléphone
Shengrui Wang	shengrui.wang@usherbrooke.ca	D4-1018-1	+1 819 821-8000 x62022

FACULTÉ DES SCIENCES,
DÉPARTEMENT D'INFORMATIQUE

15 septembre 2024

Sommaire

Le présent travail pratique (TP) est un projet d'exploration des données. Un jeu de données contenant des profils génomiques des patients atteints des cancers est fournis. Il est question ici, à partir de ce jeu de données, de mettre en exergue les concepts de prétraitement de données vus dans le Thème 1 du cours. Plus précisément, ce TP consiste à chercher des combinaisons de plusieurs concepts et techniques pour comprendre et visualiser la séparation des données. À travers ce projet, vous allez maîtriser plusieurs techniques de traitement et acquérir une bonne capacité d'analyse.

Contents

1	Jeu de données et énoncé du problème	1
1.1	Jeu de données	1
1.2	Énoncé du problème	1
2	Travail à faire	3
2.1	Programmation	3
2.2	Travail à réaliser	4
2.3	Remise du TP	5

1 Jeu de données et énoncé du problème

1.1 Jeu de données

Les données soumises à votre étude sont extraites du jeu de données RNA-Seq (HiSeq) PANCAN (<https://archive.ics.uci.edu/dataset/401/gene+expression+cancer+rna+seq>). Il s'agit d'une extraction aléatoire d'expressions génétiques des patients ayant différents (5) types de tumeurs : BRCA, KIRC, COAD, LUAD et PRAD. Le jeu de données est également disponible dans Teams du cours (dans le sous-répertoire General/travaux pratiques/TP1). Le dossier compressé comprend deux fichiers sous format tabulaire. L'un des fichiers, très gros, comprend les profils génomiques des patients. Chaque ligne correspond à un patient tandis que les colonnes sont des gènes. Dans le deuxième fichier, on trouve les différentes tumeurs associées aux différents patients.

1.2 Énoncé du problème

À partir d'une étude exploratoire portée sur ces profils génomiques, on voudrait savoir si les différents types de cancers sont bien séparées.

Méthode 1 (analyse de séparabilité sans visualisation des données) La méthode 1 vise à mesurer et présenter la séparation entre les classes par une fonction de séparation. Une telle fonction possible est présentée dans les parties 1 et 2 ci-dessous. **Pour cette méthode, vous présentez vos résultats d'analyse par des tableaux** car vous calculez ces mesures quantitatives sur **TOUTES**¹ les attributs (variables). Cette méthode est intuitive et sert à se familiariser avec des mesures de distance et des mesures de qualité de classe.

1. **Séparabilité** de classe : On peut étudier la séparation des données par analyse de deux types de mesures, la **cohésion** et la **séparation**. Pour ce TP, on définit la cohésion par une formule appelée distance intra-classe, et la séparation par une formule appelée distance inter-classe.

- Une distance intra-classe, de la classe BRCA par exemple, est définie comme étant la distance maximale entre un patient quelconque de la classe BRCA et le centre de cette classe. Formellement, pour une classe de données $C = \{x_1, x_2, \dots, x_n\}$ de n patients, la distance intra-classe ($dist_{intra}(C)$) est définie comme suit,

$$dist_{intra}(C) = \max\{dist(x_i, x_C) \mid \forall x_i \in C\}$$

Ici $dist()$ est une mesure choisie (par ex. la distance Euclidienne), x_C le centre de la classe C (généralement calculé comme étant la moyenne des données de C).

¹On parle ici toutes les variables de votre ensemble réduit des données tel que spécifié au début de la section 2.2 de ce document.

- Une distance inter-classe (par ex. entre BRCA et KIRC) est définie comme étant le minimum des deux distances suivantes : la distance minimale entre un objet quelconque de la classe BRCA et le centre de la classe KIRC, et la distance minimale entre un objet quelconque de la classe KIRC et le centre de la classe BRCA.

Formellement, étant donnée deux classes $C_1 = \{x_1, x_2 \dots, x_{n_1}\}$ et $C_2 = \{y_1, y_2 \dots, y_{n_2}\}$ de n_1 et n_2 patients respectivement, la distance inter-classe ($dist_{inter}(C_1, C_2)$) est définie comme suit,

$$dist_{inter}(C_1, C_2) = \min\left(dist(C_1, C_2), dist(C_2, C_1)\right)$$

Avec

$$dist(C_1, C_2) = \min\{dist(x_i, y_{C_2}) \mid \forall x_i \in C_1\}$$

$$dist(C_2, C_1) = \min\{dist(y_j, x_{C_1}) \mid \forall y_j \in C_2\}$$

x_{C_1} et y_{C_2} étant les centres respectifs des classes C_1 et C_2 .

- Dans cette première méthode, le test à faire pour confirmer la séparation entre les deux classes est de regarder à quel point les classes sont distantes entre elles. Pour ce faire, on se donne un indicateur de superposition $Overlap()$ de classes défini comme suit,

$$Overlap(C_1, C_2) = \frac{dist_{intra}(C_1) + dist_{intra}(C_2)}{2 \times dist_{inter}(C_1, C_2)}$$

Si $Overlap(C_1, C_2) < 1$ on pourra dire que les classes C_1 et C_2 sont bien séparées. Il est à noter que la condition $Overlap(C_1, C_2) < 1$, bien que suffisante, n'est pas nécessaire pour que les deux classes soient bien séparées. Il est à noter également que $Overlap(C_1, C_2) < 1$ dépend des attributs utilisés pour représenter les profils.

2. La séparabilité, $Overlap()$, décrite dans la partie précédente dépend de la mesure de distance utilisée et des variables (attributs) utilisées. Pour la Méthode 1, vous allez tester toutes les séparations mutuelles de classe avec l'une ou l'autre des métriques ci-dessous en utilisant toutes les variables dans votre l'ensemble de données. Pour la Méthode 2, vous allez adapter $Overlap()$ pour sélectionner des paires de variables pour la visualisation.
 - Distance Euclidienne.
 - Distance Mahalanobis.

Méthode 2 (analyse avec visualisation) La méthode 2 vise à visualiser la séparation des données par des figures de nuages de points ou de histogrammes. Il n'est pas nécessaire de fournir des résultats quantitatifs en utilisant des tableaux.

1. **Visualisation** : Si les objets (profils génomiques dans notre cas) sont représentés par une seule variable, alors, on peut utiliser l'histogramme pour représenter la distribution de chaque classe. Pour visualiser l'état de la séparation entre deux classes, on pourrait regarder conjointement la distribution des deux classes (une

illustration est donnée ici <https://seaborn.pydata.org/generated/seaborn.jointplot.html>).

Si les classes sont représentées par deux variables, on pourrait encore utiliser l'approche par l'histogramme, mais on ne génère pas de très belles figures de cette façon. La méthode la plus simple est d'afficher les nuages de points pour chaque classe (scatter plot en anglais). On peut évidemment afficher deux (ou plus) classes de données dans un même *plot* pour visualiser la séparation des classes.

2. **Sélection de variables** : Pour la visualisation, vous aller sélectionner des **meilleurs**² paires de variables selon les différentes modalités suivantes. Au moins, une des modalités doit inclure une sélection automatique par une exploitation de la mesure *Overlap()*.

- **Sélection des paires de variables originales** : Implanter une sélection automatique de variables telle que l'approche décrite à la page 37 des diapositives du Thème 1 en définissant votre propre mesures d'évaluation impliquant la mesure *Overlap()* (et critères d'arrêt). Votre implantation doit permettre de sélectionner non seulement la meilleure paire de variables pour toutes les paires de classes, mais aussi la meilleure paire de variables pour chaque paire de classes. Normalement, les mesures d'évaluation ne devront pas être les mêmes.
- **Sélection des paires de variables transformées par ACP** : Vous devez appliquer l'ACP pour générer d'abord pas moins de 15 variables (15 premières composantes principales) et sélectionner la meilleure paire de variables pour toutes les paires de classes, de même que la meilleure paire de variables pour chaque paire de classes. Pour cette sélection, vous pouvez certainement utiliser votre implantation pour la sélection des paires de variables originales (c'est un choix logique), mais vous pouvez aussi adopter n'importe quelle autre méthode de votre choix.
- **T-SNE** : La méthode permet de générer directement deux "meilleurs" dimensions. Donc il n'y pas vraiment de sélection à faire. Vous devez toutefois générer la meilleure paire de variables pour toutes les paires de classes, et la meilleure paire de variables pour chaque paire de classes.

2 Travail à faire

2.1 Programmation

Vous êtes libres d'utiliser le langage de votre choix pour faire ce TP. Vous n'avez pas à programmer les analyses comme ACP et t-SNE car vous pouvez facilement trouver des programmes de ces analyses sur l'Internet. Vous devez citer clairement les sources cependant quand vous utilisez les programmes des autres. Ne pas citer les sources sera

²Le mot "meilleur" ici signifie le meilleur candidat parmi un nombre raisonnable, non nécessairement exhaustif, des candidats. Pour n variables, $2n - 1$ paires de variables **bien sélectionnés** peuvent être raisonnables, alors que le nombre exhaustif des paires est $\frac{n(n-1)}{2}$.

considéré comme une acte de plagiat et pourrait conduire à une note de zéro en plus de s'exposer à des mesures disciplinaires. Vous pouvez faire les citations soit dans vos programmes par des commentaires soit dans une section ou un paragraphe de votre rapport du TP1 avec une liste des sources.

2.2 Travail à réaliser

Les 16382 variables dans l'ensemble de données initial pourraient poser un défi très important pour le calcul de la distance Mahalanobis et l'ACP. Pour les raisons de manque de puissance de calcul ou de manque de mémoire RAM, vous pouvez réduire la dimensionnalité de l'ensemble de données. Vous devez faire cette réduction dès le début par une sélection des variables (cette sélection peut se faire de façon aléatoire) pour constituer votre ensemble de données de départ³. Comme le choix du sous-ensemble de variables a un impact très important sur le reste des analyses, vous devez faire un effort pour garder le plus possibles les variables originales selon la capacité de votre ordinateur.

Les combinaisons suivantes d'analyse sont exigées. Il est à noter que la présentation des résultats vise toujours à montrer la séparabilité entre les classes des données.

1. Méthode 1 : vous devez réaliser la première méthode en utilisant les deux métriques de distances définies sur les variables originales. Les résultats sont à présenter dans des tableaux.
2. Méthode 2 : Pour la sélection des paires de variables, un choix de la distance sera nécessaire. Il est conseillé d'adopter la distance Euclidienne pour la raison de simplicité.

Le mode d'affichage principal est l'affichage des nuages de points à deux variables. L'ajout des histogrammes ou courbes de distribution de chacune des variables dans ces affichages est optionnel. En principe, vous devez faire une figure par paire de classes par paire de variables que vous allez obtenir.

- (a) Pour l'affichage des classes selon des variables originales ou selon des variables transformées par ACP, les points doivent être coloriés différemment par classe. Il est permis d'afficher plus de deux classes par affichage à condition évidemment que les paires de variables choisies pour ces classes soient la même.
 - (b) **Optionnellement**, pour chacune des paires de variables que vous avez choisies pour affichage, afficher conjointement aussi la distribution des paires de classes, sous forme d'histogramme, selon chaque variable impliquée. En autres termes, il s'agit d'illustrer la séparation des classe par l'affichage 1D.
3. Les résultats que vous allez obtenir vous permettront d'effectuer plusieurs analyses comparatives intéressantes. Voici des aspects d'analyses que vous devez effectuer (et inclure dans votre rapport) : transformation v.s. non-transformation des variables sur la séparation des classes; l'effet des choix de la mesure de distance (Euclidienne v.s. Mahalanobis); ACP v.s. t-SNE.
 4. Présentation des résultats : Dans votre rapport, vous devez décrire, brièvement, l'objectif et votre démarche pour chaque méthode. Vous devez fournir quelques

³Vous n'avez pas à fournir votre ensemble de données avec votre remise. Fournissez seulement les dimensions (variables) choisies pour votre ensemble.

commentaires sur les résultats de chaque méthode-combinaison pour faciliter la compréhension de votre présentation et des résultats. Si vous utilisez des ressources de l'Internet, il faut absolument citer les sources aussi. Ne pas citer les sources sera considéré comme une acte de plagiat et pourrait conduire à une note de zéro en plus de s'exposer à des mesures disciplinaires. **Il est fortement déconseillé d'utiliser des ressources Internet pour la partie de l'analyse des résultats.**

2.3 Remise du TP

- Le TP doit être fait en équipe de trois personnes ou moins;
- La date de remise du TP est le lundi 12 octobre 2026 12h00 (**midi**), **AUCUN TP NE SERA ACCEPTÉ APRÈS CETTE DATE**;
- Soignez votre rapport, une pénalité de 5% pourrait être appliquée pour un rapport mal rédigé;
- Les fichiers à soumettre sont le rapport (en Word ou pdf) et l'ensemble de vos programmes. Ne pas soumettre les données!
- N'oubliez pas d'identifier les membres de l'équipe de travail. Indiquez les noms et CIPs (ou matricules), **de même que le nom de la classe (IFT599-1, IFT799-51 ou IFT799-52)**, des membres de l'équipe dans chacun des fichiers que vous soumettez.
- La remise doit être faite par Turnin via <http://turnin.dinf.usherbrooke.ca>
Remettez une seule copie de votre TP même si les membres de votre équipe proviennent de différentes classes.